Nassim TAZIR

Analyste de données • Sciences des données

2590 rue du Verdier, H7L 3Z7, Laval, Québec • Tel : 514 571 2462 • Courriel : tazirnb@outlook.com

github.com/nassimbacha • nassimbacha.github.io • linkedin.com/in/nassim-tazir-6b25b93aa

COMPÉTENCES TECHNIQUES

Langages: Python (pandas, NumPy, scikit-learn, Matplotlib, Seaborn, PySpark), R, SQL, Java

Machine Learning: Random Forest, clustering (K-Means), ACP/AFC/ACM, régression, feature engineering, pipeline sklearn

Big Data: Hadoop MapReduce, HDFS, PySpark, Streamlit, Docker

ETL & Bases de données : MySQL, SQL Server

BI & Visualisation : Power BI, Tableau, Excel

Méthodes : Séries temporelles, validation croisée, feature importance, analyses statistiques

Gestion de projet : Agile (Scrum, Kanban), Lean Six Sigma Green Belt, PMP

PROJETS ACADÉMIQUES - COLLÈGE LA CITÉ

Système de prévision des ventes hebdomadaires - Walmart (En cours)

Outils : *Python, scikit-learn, pandas, NumPy, TimeSeriesSplit, RandomForestRegressor, XGBoost, LightGBM*

- Développement d'un pipeline complet de prévision sur 408 000+ transactions couvrant 45 magasins et 99 départements (2010-2012).
- Feature engineering avancé : variables de lag (Lag_1, Lag_2, Lag_4), moyennes mobiles (Rolling_Mean_4), indicateurs saisonniers (Black_Friday, Thanksgiving, Xmas_Week), Target Encoding sans data leakage.
- Validation temporelle avec TimeSeriesSplit (5 folds) et métrique WMAE personnalisée (pondération x5 sur périodes de fêtes).
- Phase 1 - Sélection de la meilleure variante de traitement de la cible (valeurs brutes, transformation log, imputation + flag) via Random Forest - R^2 moyen : 0.94. Analyse de la feature importance pour interprétabilité du modèle.
- Phase 2 (en cours) - Comparaison de 4 algorithmes (Random Forest, XGBoost, LightGBM, régression linéaire), sélection du meilleur modèle et optimisation des hyperparamètres.

Segmentation et analyse du risque de défaut de paiement - Cartes de crédit (UCI)

Outils : *Python, pandas, scikit-learn, Prince (PCA/AFC/MCA), KMeans, Seaborn, Matplotlib*

- Analyse exploratoire complète sur 30 000 clients : traitement des valeurs aberrantes, recodage des modalités, analyse univariée et bivariée.
- Réduction de dimensionnalité par ACP (10 composantes capturant 90% de la variance), AFC et ACM pour l'analyse des variables qualitatives.
- Segmentation K-Means (k=4) avec méthode du coude et silhouette score - identification d'un groupe à 62.6% de taux de défaut.
- Comparaison de 3 approches de clustering évaluées via radar chart (silhouette, Davies-Bouldin, équilibre des clusters).

Pipeline ML de classification - Campagne marketing bancaire (UCI)

Outils : *Python, scikit-learn, pandas, RandomForestClassifier, SelectKBest, Pipeline*

- Pipeline sklearn complet : StandardScaler, OneHotEncoder, sélection de variables par Mutual Information (k=15), RandomForestClassifier (200 arbres).
- Gestion du déséquilibre de classes (22% positifs), analyse precision/recall/F1 - accuracy finale de 98.2% sur le jeu de test.

Pipeline Big Data - Analyse de ventes avec Hadoop MapReduce et Streamlit

Outils: *Python, Hadoop (HDFS, YARN), MapReduce, Streamlit, Docker, Docker Compose*

- Déploiement d'un cluster Hadoop Dockerisé (1 master + 2 workers) pour le traitement distribué de données de ventes à grande échelle.

- 4 jobs MapReduce (CA net, Top 10, retours, paiements) avec stockage HDFS et dashboard Streamlit interactif. | github.com/nassimbacha

HISTORIQUE DE TRAVAIL

Analyste de données - Services financiers - PROIMP (Prestation analytique)
Avr. 2020 - Fév. 2024

- Extraction et préparation de données clients du portefeuille financement véhicules (~3 700 dossiers) via SQL et MySQL.
- Analyses statistiques descriptives et exploratoires sous R : suivi des KPIs clés (taux de défaut, taux de retard, volume financé, mensualité moyenne).
- Segmentation du portefeuille clients par profil de risque (clustering K-Means sous R) pour identifier les groupes à risque élevé.
- Contrôle qualité des données : détection d'anomalies, valeurs manquantes, doublons et incohérences via SQL et R - rapports qualité mensuels.
- Production de tableaux de bord et rapports automatisés sous R et Excel pour soutenir les décisions de portefeuille.

Autre Activité (Oct. 2021 - Sept. 2024) : Animation de formations et coaching certifications PMP et Scrum.

Responsable développement réseau automobile - KIA Motors, Algérie
Août 2017 - Mars 2020

- Extraction et structuration des données du parc automobile (modèles, kilométrage, âge des véhicules) via requêtes SQL Server pour alimenter les rapports d'analyse réseau remis à la direction.
- Collecte, structuration et analyse des données du parc automobile pour identifier les opportunités d'expansion du réseau.
- Nettoyage et consolidation des bases de données internes et externes pour fiabiliser les analyses de marché.
- Préparation de rapports et tableaux de bord remis aux équipes de direction.

Chargé développement réseau de distribution - RENAULT, Algérie
Déc. 2012 - Fév. 2016

- Collecte et centralisation des données relatives aux infrastructures des partenaires pour alimenter les rapports d'évaluation.
- Structuration et mise en qualité des données pour le suivi des projets via bases de données internes et Excel.
- Préparation de jeux de données et rapports standardisés pour soutenir les décisions d'agrément des partenaires.

ÉDUCATION

Diplôme d'études collégiales - Sciences des données appliquées
Collège La Cité, Ottawa (Ontario) • *Sept. 2024 - Avr. 2026*

Master en prévision et analyse économique
Institut Supérieur de Gestion et de Planification, Algérie • *2021* • *Équivalence WES Ref. 5666449IMM*

CERTIFICATIONS

PSM I - Professional Scrum Master • PSPO I - Professional Scrum Product Owner

LSSGB - Lean Six Sigma Green Belt • PMP - Project Management Professional • CESAM - Statistiques appliquées (Fév. 2024)

COMPÉTENCES INTERPERSONNELLES

Bilingue français & anglais • Travail collaboratif en équipe multidisciplinaire • Capacité d'analyse et résolution de problèmes • Adaptabilité et apprentissage continu